

Respiratory Risk Analytics

NF21 Project — Pollution Atmosphérique et Maladies Respiratoires

Yves APEAPEA-MIGUE

Malcolm ARIDORY

Hélène CHEVALIER

Yesmine FATHALLAH

Gwendal RODRIGUES

[UTT](#) — [ISI1](#) — [GitHub](#)

Table des matières

1. Business Understanding
2. Data Understanding
3. Data Preparation
4. Modelization
5. Prédications & Scenarii
6. Implémentation Omniscopes
7. Évaluation des Modèles
8. Déploiement

9. Conclusion

**Quelle est la relation entre la pollution
atmosphérique et l'incidence des
maladies respiratoires à l'échelle
mondiale ?**

Contexte

- Pollution = déterminant majeur de santé
- Effets variables selon **territoires, périodes, polluants**
- Enjeu prioritaire pour les autorités sanitaires

Objectifs du projet

- **Quantifier** la relation pollution ↔ maladies respiratoires
- **Identifier** les zones prioritaires d'intervention
- **Prédire** l'évolution des maladies
- **Recommander** des actions prioritaires

Méthodologie : CRISP-DM — Business Understanding → Data Understanding → Data Preparation → Modeling

Business Understanding

- **Domaine** : Santé publique & environnement
- **Problème** : Lien qualité de l'air ↔ santé humaine
- **Enjeu** : Orienter les politiques de prévention avec des données

Acteurs impliqués :

- Collectivités territoriales & Agences de santé publique
- Ministères (santé, environnement) & Commission Européenne
- **Citoyens** — bénéficiaires directs des politiques de réduction

Question centrale : *Quelle est la relation entre la pollution atmosphérique et l'incidence des maladies respiratoires à l'échelle mondiale ?*

 Diagnostiquer Zones à hautes émissions/ maladies	 Expliquer Liens temporels pollution ↔ santé	 Prédire Évolution selon pollution	 Recommander Actions de réduction
--	--	--	---

Environnementaux

- Réglementations européennes
- Protection de la biodiversité
- Réduction des émissions

Sanitaires

- Asthme, BPCO, cancers pulmonaires
- Facteur aggravant majeur
- Populations vulnérables

Économiques

- Réduction dépenses hospitalières
- Moins d'arrêts de travail
- Gains de productivité

Sociaux

- Qualité de vie
- Équité territoriale
- Accès à un air sain

1. Identification des zones prioritaires

- Utiliser le **data mining** pour cibler les territoires à forte marge de réduction

2. Réduction de l'incidence

- Réduire l'incidence des maladies respiratoires de **5%** dans les zones sensibles
- Diminuer les émissions des polluants les plus dangereux de **10%**

3. Identification des polluants critiques

- Identifier les polluants ayant le plus d'impact sur la santé respiratoire



EDGAR — Commission Européenne

Emissions Database for Global
Atmospheric Research

- 6 000 lignes/polluant
- Année, Pays, Secteur, Polluant, Quantité (Gg)
- **Émissions atmosphériques**



GBD 2023 — IHME

Global Burden of Disease

- 30 000 lignes
- Année, Pays, Sexe, Incidence, Mortalité
- **Maladies respiratoires**

Période : 1980–2022 • **Couverture** : 197 pays

Dans le périmètre

- **Géographie** : 197 pays
- **Période** : 1980–2022 (43 ans)
- **Polluants** : PM2.5, PM10, NO_x, SO₂, CO, NH₃, NMVOC, BC, OC
- **Maladies** : Asthme, BPCO, Cancer, Pneumoconioses

Hors périmètre

- Analyses intra-urbaines
- Déterminants sociaux individuels

Parties prenantes

- Commanditaire : ARS
- Équipe projet : Analystes données
- Secondaires : Santé Publique France, ATMO

Data Understanding

Caractéristique	EDGAR	GBD 2023
Nombre de pays	215	204
Période	1970–2022	1980–2023
Variables	9 polluants	5 maladies
Granularité	Pays, année, secteur	Pays, année, sexe
Unité	Kilotonnes (kt)	Taux /100k hab.


- **Polluants** : PM2.5, PM10, NO_x, SO₂, CO, NH₃, NMVOC, BC, OC
- **Maladies** : Cancer poumon, BPCO, Asthme, Pneumoconioses, Maladies interstitielles


✓ Points forts

- Complétude exceptionnelle : > **99.99%**
- Valeurs manquantes < 0.01%
- Sources fiables (CE, IHME)

🔗 Jointure


- Clé : Code ISO 3166-1 alpha-3
- Période commune : 1980–2022
- **197 pays** correspondants






Observations

- Forte asymétrie positive : quelques pays émettent beaucoup plus que la moyenne




Observations


- Hommes = taux plus élevés
- **Cancer poumon** : H/F $\approx 2-3x$
- BPCO : différence significative
- Facteurs : tabac, exposition pro



Pic en 1990 •  Polluants très corrélés •  CO = plus émis



BPCO : diminution globale • ➡ Cancer : stabilité • ✓ Asthme mortel : baisse



Top 5 émetteurs

1. Chine
2. États-Unis
3. Inde
4. Russie
5. Brésil


Reflète activité industrielle et population

Geographic Distribution of Respiratory Disease Death Rates


(Average annual rate per 100,000 inhabitants, log scale)

Cancer de la trachée


MPOC (Maladie pulmonaire obstructive chronique)






Cancer : Europe Est, Amérique Nord • **BPCO** : Asie Sud-Est, Afrique




NH3 Emissions



OC Emissions





Secteurs dominants

1. Transport routier
2. Industrie manufacturière
3. Production d'énergie
4. Agriculture

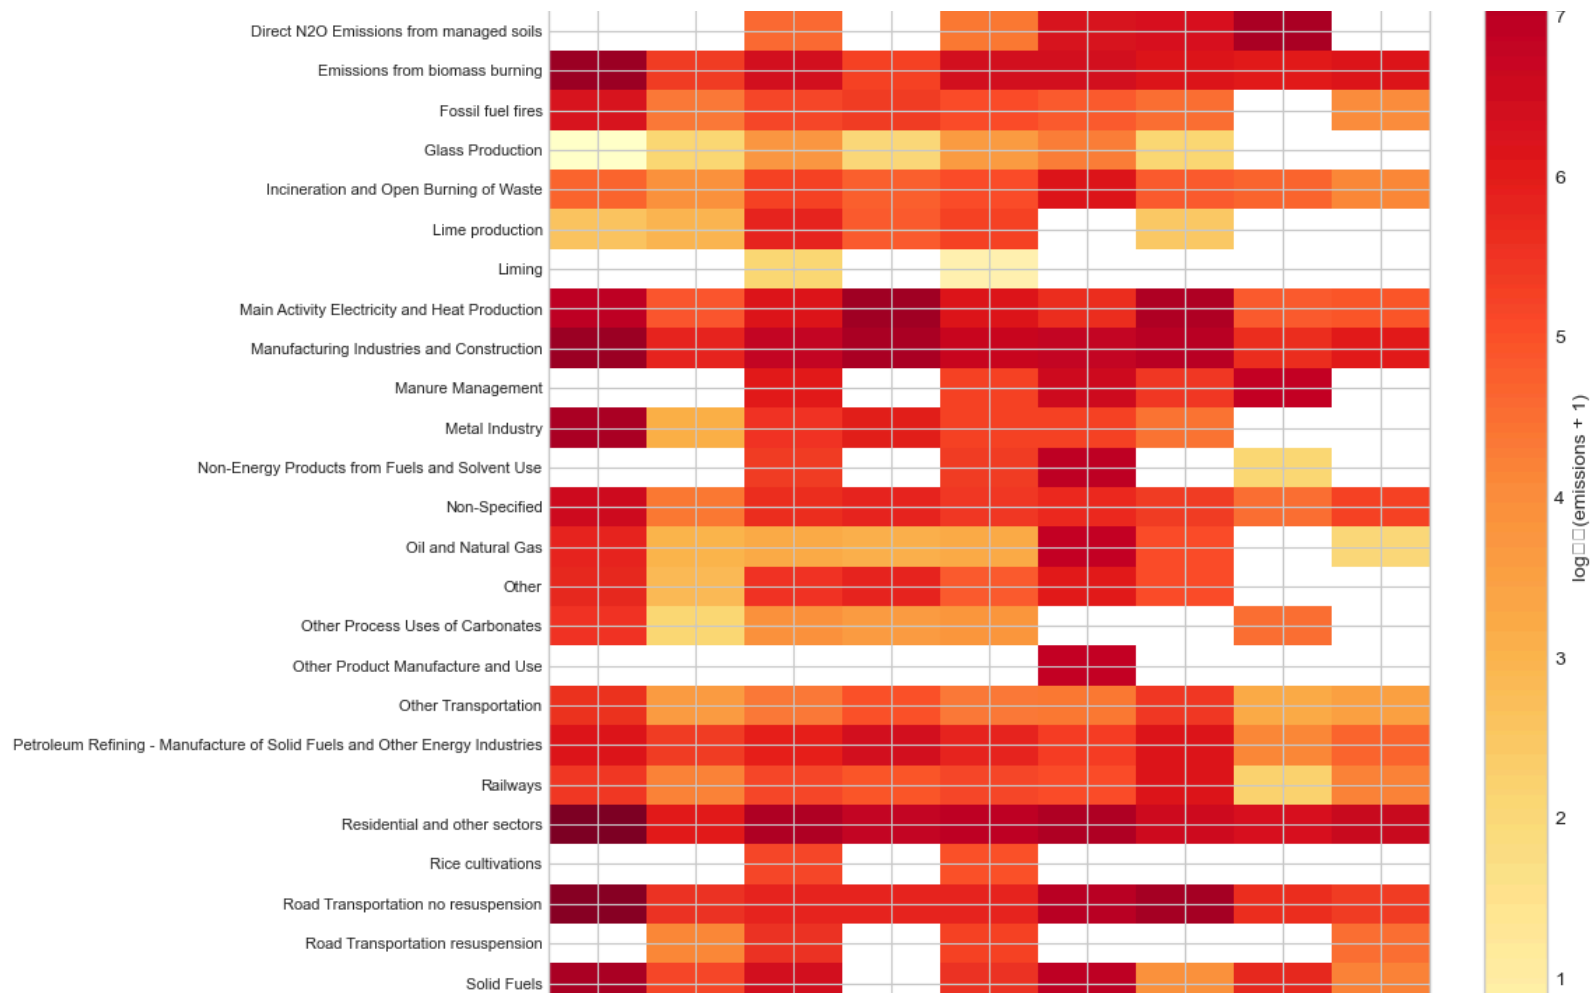


Associations

- Transport → NO_x, CO
- Agriculture → NH₃
- Industrie → SO₂, PM

Heatmap secteurs x polluants


24 / 64





Observations clés

- **PM2.5, PM10** : corrélations positives modérées
- **NH₃, OC** : plus fortes avec cancer
- **BPCO** : corrélée à la plupart des polluants



Multicolinéarité : polluants très corrélés entre eux ($r > 0.8$) → attention modélisation!

✅ **Qualité des données**

- Complétude > 99.99%
- 197 pays, 43 ans
- Outliers < 2%

📊 **Conclusions**

- Corrélations significatives
- BPCO = maladie la plus corrélée
- Tendance baisse des décès


⚠️ **Points d'attention**

- Forte multicolinéarité
- Différences H/F significatives
- Disparités géographiques

💡 **Recommandations**

- Transformation logarithmique
- ACP pour multicolinéarité

Data Preparation



Outils

Polars, Pandas, Parquet



Dataset final

8 471 lignes × 17 cols



Pourquoi Polars?

Rust, 10-100x plus rapide

❌ Problème

- GBD : noms en français mal traduit
- Articles aléatoires (“La Chine”, “France”)
- Apostrophes mal encodées
- Pas de codes ISO dans GBD

✅ Solution

- Table de correspondance manuelle
- Mapping FR → EN → ISO
- Export dans `country_mapping.csv`
- Jointure sur codes ISO 3166-1 alpha-3

Résultat : 197 pays correctement mappés

Chargement & Transformations

- Format Parquet (compression)
- **Log-transform** : $x' = \log(1 + x)$
- **StandardScaler** : $x' = \frac{x - \mu}{\sigma}$

Séparation & Variables

- Train : 80% / Test : 20%
- **9 features** : CO, SO₂, NO_x, PM...
- **3 cibles** : Cancer, BPCO, Pneumo
- (Asthme exclu : corrélation ≈ 0)

Hypothèse : délai biologique entre exposition et maladie

Maladie	Lag 0	Lag 3	Lag 6	Lag 9
Cancer	0.857	0.863	0.872	0.866
Pneumo	0.806	0.787	0.737	0.793
BPCO	0.794	0.781	0.792	0.812

Pas de pattern consistant → **Lag = 0** retenu

Modelization

Machine Learning classique

Bibliothèque : **scikit-learn**

Modèles testés :

- Ridge (régression linéaire)
- Random Forest
- **Gradient Boosting** ✓

Deep Learning

Bibliothèque : **PyTorch**

Architecture MLP :

- 2 couches cachées (64 $\rightarrow$ 32)
- Activation ReLU
- Sortie linéaire

Modèle	R ²	RMSE
Ridge	0.156	9188.9
Random Forest	0.737	5128.3
Gradient Boosting	0.772	4782.2

- **Ridge** : trop simple, sous-apprentissage
- **Random Forest** : bon, robuste aux outliers
- **Gradient Boosting** : **meilleure performance**, corrige les erreurs itérativement


```
class MLP(nn.Module):  
    def __init__(self, n_features):  
        super().__init__()  
        self.layers = nn.Sequential(  
            nn.Linear(n_features, 64),  
            nn.ReLU(),  
            nn.Linear(64, 32),  
            nn.ReLU(),  
            nn.Linear(32, 1)  
        )  
  
    def forward(self, x):  
        return self.layers(x)
```

Architecture

- Entrée : 9 features
- Couche 1 : 64 + ReLU
- Couche 2 : 32 + ReLU
- Sortie : 1 (linéaire)

Hyperparamètres

- Optimizer : Adam
- Loss : MSE
- LR : 0.001, Epochs : 500




🔄 Processus d'apprentissage

1. Forward pass : données → prédiction
2. Calcul loss : erreur vs réel
3. Backpropagation : calcul gradients
4. Mise à jour : ajustement poids

⚠ Enjeux

- Overfitting vs Underfitting
- Équilibre learning rate/epochs



Underfitting

- Modèle trop simple
- Ne capture pas les patterns

Overfitting

- Modèle trop complexe
- Mémorise le bruit

Maladie	R ²	Top polluants
Cancer	0.923	SO ₂ , NH ₃ , NO _x , OC, CO
Pneumo	0.805	OC, NH ₃ , NMVOC, PM10, NO _x
BPCO	0.901	NH ₃ , OC, NMVOC, SO ₂ , NO _x

 **Excellentes performances** sur les données de test

Maladie	R ²
Cancer	0.872
Pneumo	0.956
BPCO	0.637

✓ Forces

- Excellente perf. Pneumoconiose
- Meilleure généralisation

⚠ Faiblesses

- Moins bon sur BPCO
- Plus difficile à interpréter


Critère	GB	ANN	Meilleur
Cancer	0.923	0.872	GB
Pneumo	0.805	0.956	ANN
BPCO	0.901	0.637	GB
Interpolation	Excellent	Bon	GB
Extrapolation	Limité	Meilleur	ANN
Interprétabilité	Bonne	Faible	GB

Prédictions & Scenarii


Simuler l'impact de réductions d'émissions sur la mortalité

Scénario	Réduction	Émissions
Baseline	0%	100%
Modéré	−5%	95%
Ambitieux	−10%	90%
Très ambitieux	−20%	80%

Année référence : 2022 • Projection : 10 ans



⚠ **Incohérences** : réduction 20% → augmentation mortalité cancer? Limites de l'**extrapolation**



✅ **Résultats plus cohérents** : diminution mortalité avec réduction émissions

! Limites identifiées


- R^2 performant $\neq$ prédictions cohérentes hors distribution
- GB : mauvais pour extrapolation
- ANN : quelques anomalies mineures

🔍 Facteurs non inclus


- Politiques de santé
- Évolution démographique
- Progrès médicaux
- Changement climatique

Les prédictions indiquent des **tendances**, pas des prévisions précises

Implémentation Omniscope



Réplication de la pipeline Python avec les blocs natifs




Configuration


- Type : Linear Regression
- Split : 80/20
- Cible : BPCO

Résultats

- $R^2 = 0.79$
- Comparable à sklearn



Comparaison prédictions vs valeurs réelles



Limite : Régression linéaire → prédiction d'une droite. Pas d'export modèle!

✓ Avantages

- Interface conviviale
- Dashboards interactifs
- Pas besoin de coder
- Intégration scripts Python/R

✗ Limites

- Choix modèles limité
- Pas de contrôle hyperparamètres
- **Export impossible**
- MARS : problème de convergence

Omniscope = exploration & dashboards • Modélisation avancée → **Python**

Évaluation des Modèles

Métriques utilisées

- R^2 : variance expliquée
- **RMSE** : erreur quadratique
- Analyse des résidus

Séparation des données

- Train : 80% (entraînement)
- Test : 20% (évaluation)
- Graine aléatoire fixée

Méthodes appliquées

- Comparaison multi-modèles
- GridSearchCV (hyperparams)
- Test d'extrapolation

Points d'attention

- Pas de k-fold CV
- Split non temporel
- Pas de validation externe

Critère	GB	ANN	Note
R ² Cancer	0.923	0.872	GB meilleur
R ² BPCO	0.901	0.637	GB meilleur
R ² Pneumo	0.805	0.956	ANN meilleur
Extrapolation	✗ Incohérent	✓ Cohérent	ANN meilleur
Interprétabilité	✓ Bonne	✗ Opaque	GB meilleur

R² élevé ≠ prédictions fiables hors distribution !

Déploiement

1. Sauvegarder le modèle

- sklearn : `joblib.dump()`
- PyTorch : `torch.save()`
- 1. Scaler, transformations

2. Créer une API

- FastAPI / Flask
- Endpoint `/predict`
- Validation des entrées

3. Conteneuriser

- Dockerfile
- Environnement reproductible
- CI/CD automatisé

4. Déployer en cloud

- AWS SageMaker
- GCP Vertex AI
- Azure ML

Conclusion

Data Understanding

- 197 pays, 43 ans de données
- Corrélations significatives
- BPCO = plus corrélée
- Forte multicolinéarité

Modélisation

- GB : $R^2 \approx 0.90$ (interpolation)
- ANN : meilleure extrapolation
- Polluants : NH_3 , OC, SO_2

Objectifs atteints

-  Quantification relations
-  Polluants critiques identifiés
-  Zones prioritaires
-  Prédictions = tendances

Outils maîtrisés

- Polars, Pandas, NumPy
- scikit-learn, PyTorch
- Omniscope, CRISP-DM

Pour les décideurs

- Cibler NH_3 (agriculture)
- Cibler SO_2 (industrie)
- Prioriser zones BPCO
- Surveiller PM2.5 et OC

Pour la recherche

- Facteurs socio-économiques
- Analyses intra-urbaines
- Modèles de panel temporel
- Variables contrôle (PIB)

 **Limites** : Corrélation $\neq$ causalité • Extrapolation limitée • Granularité pays

**Merci pour votre
attention !**

Questions ?

Références



Données : EDGAR v8.0, GBD 2023



Méthodologie : CRISP-DM, Gradient Boosting, Multilayer Perceptron



Outils : scikit-learn, PyTorch, Polars, Omniscope



[Dépôt GitHub](#)