

Respiratory Risk Analytics

Pollution Atmosphérique & Maladies Respiratoires

Y. APEAPEA-MIGUE • M. ARIDORY • H. CHEVALIER • Y. FATHALLAH • G.
RODRIGUES

NF21 — UTT — Automne 2025

Agenda

1. Data Understanding
2. Chaînes de Valorisation
3. Data Preparation
4. Modeling
5. Implémentation Omniscope
6. Prédications & Scenarii
7. Conclusion

**Quelle relation entre pollution
atmosphérique et maladies
respiratoires ?**



197 pays

Couverture
mondiale




9 polluants

EDGAR
Database



5 maladies

GBD 2023



43 ans

1980–2022

Objectif : Identifier les leviers de réduction de la mortalité respiratoire



Diagnostiquer

Où sont les zones critiques ?



Expliquer

Quels liens temporels ?



Prédire

Évolution future ?



Recommander

Actions prioritaires ?

Geographic Distribution of Respiratory Disease Death Rates

(Average annual rate per 100,000 inhabitants, log scale)

Cancer de la trachée

MPOC (Maladie pulmonaire obstructive chronique)



Distribution géographique des maladies respiratoires — disparités majeures

Data Understanding

EDGAR

Commission Européenne

- 9 polluants atmosphériques • Granularité : pays, année, secteur • Unité : kilotonnes (kt)

PM2.5 • PM10 • NO_x • SO₂ • CO
NH₃ • NMVOC • BC • OC

GBD 2023

IHME — Global Burden of Disease


- 5 maladies respiratoires • Taux standardisés par âge • Unité : décès/100k hab.










Cancer • BPCO • Asthme
Pneumoconioses • Maladies
interstitielles


99.99%

Complétude


- 197 pays fusionnés •
- 8 471 observations •
- Outliers < 2%









Pic en 1990 • CO = polluant dominant • Polluants très corrélés



BPCO ↘ • Cancer stable • Impact des progrès médicaux



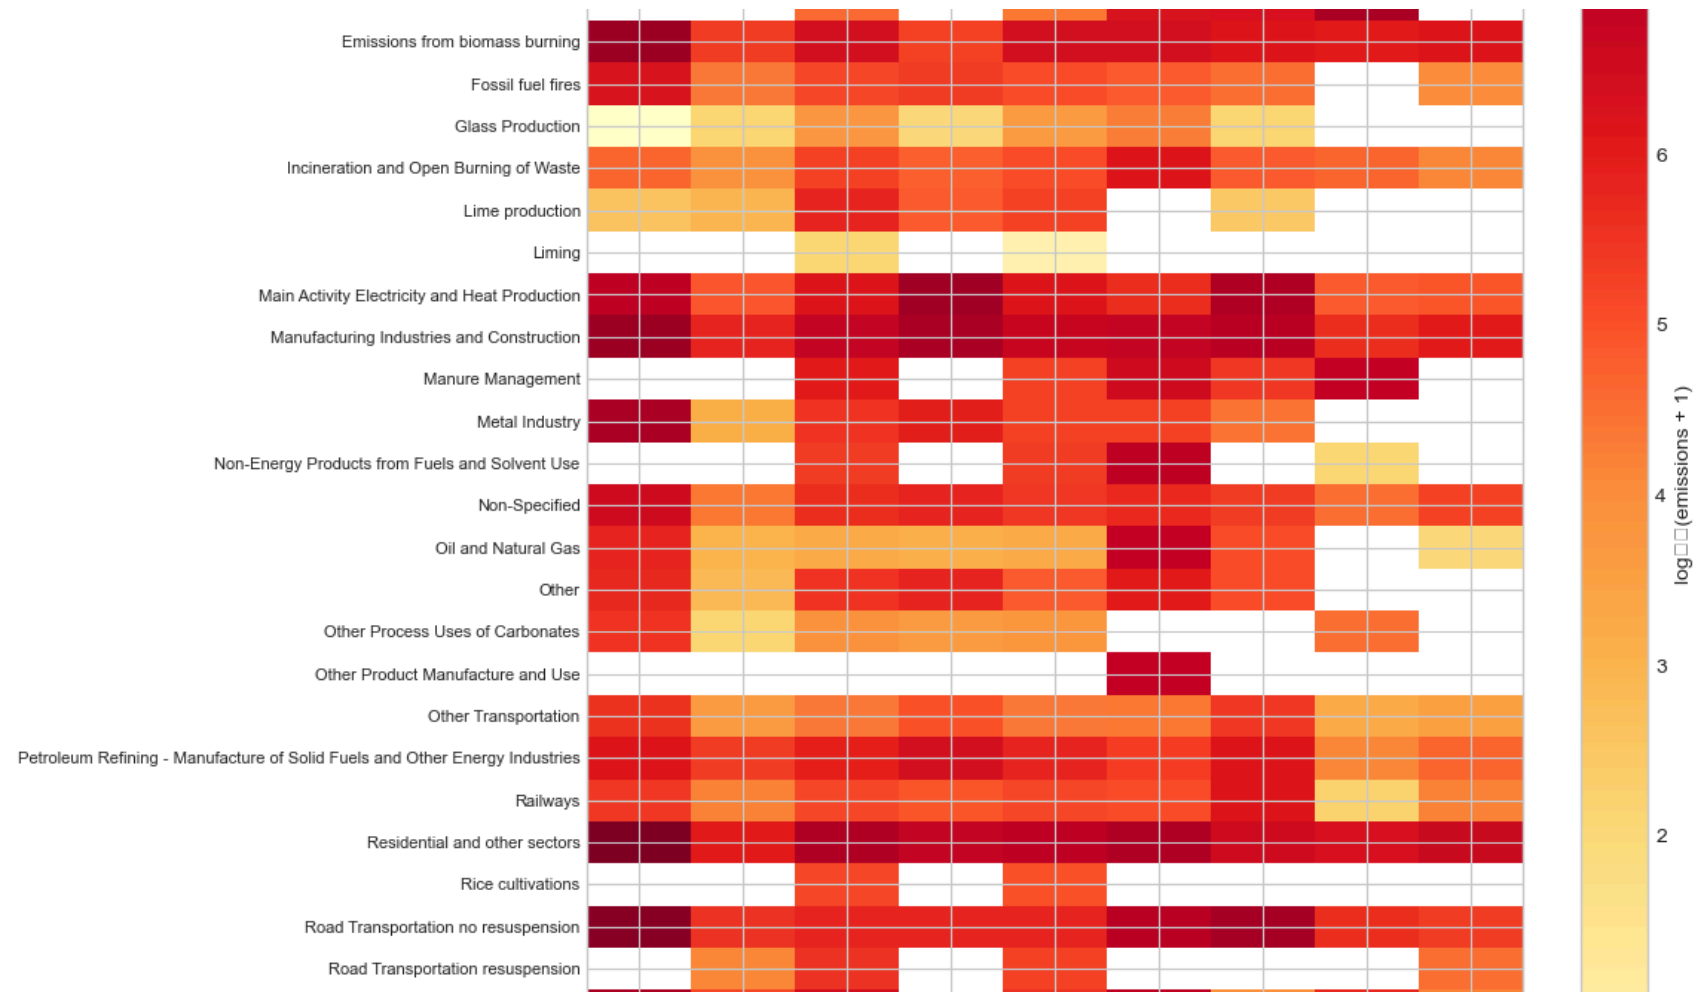


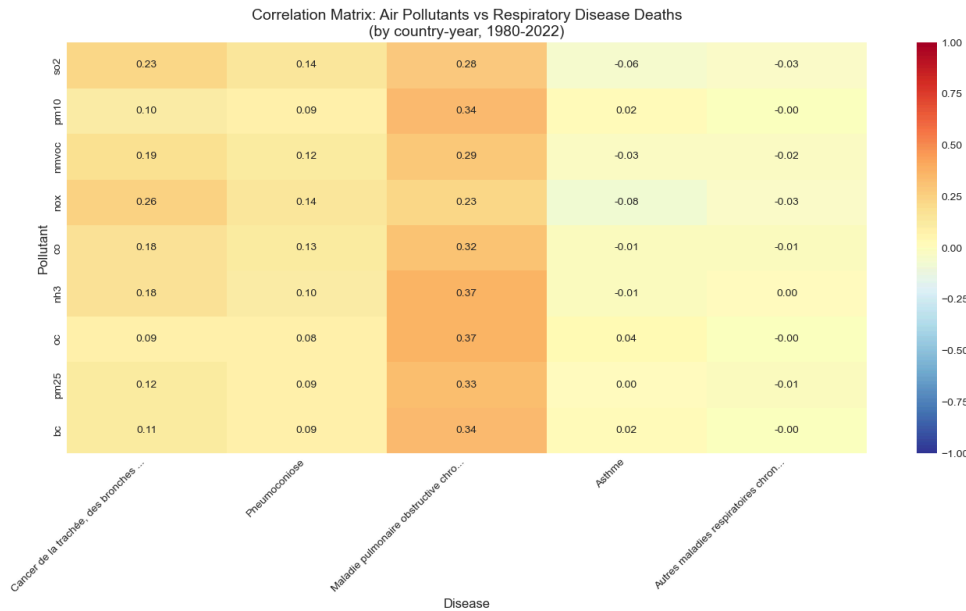
Cancer poumon

H/F $\approx$ 2-3x

BPCO Écart
significatif

*Facteurs : tabac,
exp. pro.*





Observations clés

- **BPCO** : plus corrélée • PM2.5,
- PM10 : impact universel • NH₃, OC : cancer poumon

⚠ **Multicolinéarité** Polluants
corrélés entre eux ($r > 0.8$)

Chaînes de Valorisation

Collecte			
EDGARnGBD	HarmonisationnISO 3166	CorrélationsnPearson	HeatmapsnScatter plots
Pythonnrequests	PolarsnPandas	ScipynOmniscopn	MatplotlibnOmniscopn

Objectif : Identifier les liens statistiques émissions ↔ mortalité

Collecte			
	Agrégationnpays- année	ClassementsnTendances	Bar chartsnCourbes
	group_byfilter	NumpynOmniscopSeabornnOmniscop	

Objectif : Comprendre la distribution spatiale et l'évolution temporelle

Préparation ML			
Log-transform StandardScaler	GradientBoosting	MLPnPyTorch	R ² , RMSEnComparaison
Polarsnsklearn GridSearchCVnOmniscope		AdamnMSE	joblibnOmniscope

Objectif : Prédire la mortalité à partir des émissions de polluants

Data Preparation

EDGAR (Excel) → Polars → Dépivotage



Jointure ISO 3166 + Année



GBD (CSV) → Polars → Mapping FR→EN

Dataset final : **8 471 lignes × 17 colonnes** • Format **Parquet**

Transformations

Log-transform

$$x' = \log(1 + x)$$

StandardScaler

$$x' = \frac{x - \mu}{\sigma}$$

Split : 80% train / 20% test

Variables

9 features (polluants) CO, SO₂, NO_x, PM2.5, PM10 NH₃, NMVOC, BC, OC

3 cibles (maladies) Cancer • BPCO
• Pneumoconiose

(Asthme exclu : corrélation ≈ 0)

Modeling



scikit-learn

Machine Learning classique


- Ridge • Random Forest •
Gradient Boosting ✓



PyTorch

Deep Learning


- MLP (Perceptron multicouche) •
2 couches cachées • Activation
ReLU



Architecture MLP

Entrée (9) → Dense(64) → ReLU
→ Dense(32) → ReLU
→ Dense(1) → Sortie

Hyperparamètres • Optimizer :
Adam • Loss : MSE • LR : 0.001 •
Epochs : 500



Équilibre crucial : généralisation sans mémorisation du bruit

Modèle	R^2	RMSE
Ridge	0.156	9 188
Random Forest	0.737	5 128
Gradient Boosting	0.772	4 782

Gradient Boosting retenu — correction itérative des erreurs


Maladie	R ²	Top 5 polluants
Cancer	0.923	SO ₂ (25%), NH ₃ (17%), NO _x (13%)
BPCO	0.901	NH ₃ (18%), OC (18%), NMVOC (15%)
Pneumoconiose	0.805	OC (16%), NH ₃ (15%), NMVOC (13%)


NH₃ et **OC** : polluants les plus prédictifs

Maladie	R ² GB	R ² ANN
Cancer	0.923	0.872
Pneumoconiose	0.805	0.956
BPCO	0.901	0.637

ANN excellent sur Pneumoconiose • GB plus robuste globalement

Implémentation Omniscope







Configuration

- Linear Regression •
- Split 80/20 • Cible : BPCO

Résultat


$$R^2 = 0.79$$






Régression linéaire : tendance générale, pas de nuances

Prédictions & Scenarii



⚠ *Incohérences en extrapolation — limites des arbres de décision*



✓ *Tendances cohérentes — meilleure généralisation*

Conclusion

✓ Résultats

- Corrélations significatives NH_3 , OC , $\text{SO}_2 \leftrightarrow \text{BPCO}$, Cancer
- Modèles performants $R^2 > 0.80$ (interpolation)
- Polluants critiques identifiés
- Pipeline reproductible

⚠ Limites

- Corrélation $\neq$ causalité
- Extrapolation limitée (GB)
- Facteurs confondants (*PIB, soins, démographie*)
- Granularité pays uniquement

Merci de votre attention

 **Contact : équipe projet**

 **GitHub : github.com/malcolm-a/nf21_respiratory_diseases**