




RESPIRATORY RISK ANALYTICS

Application du CRISP-DM dan un projet
Data sur la pollution atmosphérique et les
maladies respiratoires

APEAPEA MIGUE Yves
ARIDORY Malcolm
CHEVALIER Helena
FATHALLAH Yasmine
RODRIGUES Gwendal

INTRODUCTION

- Objectif global : comprendre, expliquer et anticiper les risques respiratoires
- Contexte : enjeu majeur de santé publique et de dérèglement climatique
- Projet d'analyse de données appliquant la méthodologie CRISP-DM

SOMMAIRE

Planification
du projet

Problématique

Données

Préparation

Modélisation

Évaluation

Déploiement

Conclusion


PLANIFICATION DU PROJET

Méthodologie CRISP-DM

Approche itérative

Organisation en équipe par intérêts

Diagramme de Gantt



PROBLÉMATIQUE & OBJECTIFS

Quelle est la relation entre pollution de l'air et maladies respiratoires ?



Objectifs opérationnels :



Identifier les polluants les plus impactants



Comparer les risques selon les zones géographiques



Appuyer la décision publique en santé environnementale

DONNÉES UTILISÉES

Données environnementales :

- PM2.5, PM10, NO2, O3, SO2
- Mesures annuelles par pays

Données de santé :

- Incidence et mortalité des maladies respiratoires
- Données agrégées à l'échelle nationale

Conclusion de la phase Data Understanding : L'hétérogénéité des données rend la Data Preparation une phase clé du projet

ENJEUX DE LA DATA PRÉPARATION



Améliorer la qualité des données



Harmoniser les formats et échelles



Rendre les données comparables et exploitables



Préparer la modélisation

CHAINES DE VALORISATION DE LA DATA PREPARATION

- Nettoyage pollution
 - Nettoyage données santé
 - Fusion datasets
 - Création indicateurs
-

MODÉLISATION - APPROCHE MÉTHODIQUE



Régressions statistiques



Réseaux de neurones simples (PyTorch)



Variables explicatives : polluants
atmosphériques

MODÉLISATION - IMPLÉMENTATION OMNISCOPE

- Exploration visuelle
 - Corrélations
 - Analytics intégrée
-

MODÉLISATION - RÉSULTATS CLÉS



Corrélation forte entre PM2.5 / PM10 et maladies respiratoires



Disparités géographiques importantes



Confirmation de tendances connues par une approche data-driven

EVALUTATION

Évaluation technique :


- Stabilité des modèles
- Cohérence des résultats

Évaluation métier :

- Pertinence pour la santé publique
 - Lisibilité des indicateurs produits
-

DÉPLOIEMENT

Cas d'usage envisagés :



Dashboards de
surveillance sanitaire



Aide à la décision pour
politiques publiques



Sensibilisation aux risques
environnementaux

LIMITES DU PROJET

- Limites :
 - Données agrégées (pas individuelles)
 - Corrélation $\neq$ causalité
 - Perspectives :
 - Données plus fines (régionales)
 - Intégration de facteurs socio-économiques
-

CONCLUSION

- CRISP-DM comme cadre structurant du projet
 - Importance majeure de la Data Preparation
 - La data comme levier pour comprendre et prévenir les risques respiratoires
 - Projet à fort impact sociétal et environnemental
 - Projet formateur sur différents aspect des projets Data
-

MERCI DE VOTRE ATTENTION

Des questions ?

